

PONTIFÍCIA UNIVERSIDADE CATÓLICA DE GOIÁS
ESCOLA POLITÉCNICA E DE ARTES
GRADUAÇÃO EM ENGENHARIA DE COMPUTAÇÃO



**IMPUTAÇÃO DE VALORES AUSENTES EM DADOS CLIMÁTICOS DO INMET
UTILIZANDO ERA5 PARA TREINAMENTO DE MODELOS PREDITIVOS
BASEADOS EM TRANSFORMERS**

DAVI AQUILA DE SOUZA DIAS

GOIÂNIA
2025

DAVI AQUILA DE SOUZA DIAS

**IMPUTAÇÃO DE VALORES AUSENTES EM DADOS CLIMÁTICOS DO INMET
UTILIZANDO ERA5 PARA TREINAMENTO DE MODELOS PREDITIVOS
BASEADOS EM TRANSFORMERS**

Trabalho de conclusão de curso apresentado ao curso de Engenharia de Computação, como requisito parcial para a obtenção do Título de Bacharel em Engenharia de Computação, Escola Politécnica e de Artes da Pontifícia Universidade Católica de Goiás

Prof. Orientador:

Me. Maria José Pereira Dantas Banca
examinadora:

Prof Dr Felipe Correa Veloso Dos Santos

GOIÂNIA
2025

1 INTRODUÇÃO

Séries temporais meteorológicas e climáticas são insumos críticos para múltiplas áreas: energia, saúde pública, agropecuária, recursos hídricos, qualidade do ar, planejamento urbano e defesa civil. Na prática, interrupções de operação a manutenção de sensores, substituição de instrumentação, falhas de comunicação e interrupções elétricas resultam em falhas e lacunas nos registros, o que compromete a qualidade das análises, modelos e decisões. A literatura categoriza os mecanismos de ausência como (1) Ausência totalmente aleatória (MCAR), os valores ausentes são independentes de quais quer outros valores observados; (2) Ausência aleatória (MAR), em que os valores tem alguma relação ou dependência dos valores observados; (3) Ausência não aleatória (MNAR), em que os valores ausentes dependem tanto dos valores observados como os não observados, o que tem implicações distintas no viés e na incerteza dos métodos de preenchimento (Alabadla et al., 2022; Lien; Do; Nguyen, 2023).

Para lidar com lacunas e variações nas observações, reanálises atmosféricas como ERA5 e ERA5-Land oferecem campos espaço-temporais fisicamente consistentes, abrangendo extensos períodos com resolução horária/subdiária. Têm sido empregados para enriquecer e validar séries históricas. Em particular, o ERA5-Land oferece uma maior resolução espacial ($0,1^\circ \times 0,1^\circ$ contra $0,25^\circ \times 0,25^\circ$ do ERA5) estudos no Nordeste do Brasil indicam boa concordância entre o ERA5-Land e dados de estações automáticas, com erros quadráticos médios (RMSE) inferiores a $0,60^\circ\text{C}$, e altos coeficientes de determinação elevados (Araújo et al., 2022; Varotsos; Katavoutas; Giannakopoulos, 2023). Em resumo reanálises são fontes auxiliares valiosas para ajustar e regularizar séries de superfície, desde que sejam devidamente ajustadas ao microclima local.

Do ponto de vista metodológico, existe um gradiente que vai de técnicas estatísticas tradicionais (média sazonal, interpolação linear, kriging, ARIMA) a aprendizado de máquina (KNN e florestas aleatórias) e, mais recentemente, aprendizado profundo (RNNs como GRU-D, arquiteturas *time-aware* e modelos baseados em atenção). *Transformers* especializados em imputação têm mostrado avanços significativos em séries multivariadas e com lacunas longas, ao identificar dependências de longo alcance e padrões sazonais/diários (Weerakody et al., 2021; Yildiz; Koç; Koç, 2022). Entre os representantes, o SAITS (Du; Côté; Liu, 2023) e variantes *time-aware* como o TA-SAITS (Sharma et al., 2023) são referências consolidadas. Em cenários espaciotemporais, arquiteturas híbridas CNN-Transformer têm se destacado por combinar extração local (convoluções) e dependências globais (atenção), com resultados promissores em dados atmosféricos multivariados e esparsos (Hu; Dong; Liu, 2025). Revisões setoriais focadas em clima reforçam essas tendências e discutem quando reanálises e ensembles ajudam (Alejo-Sanchez et al., 2025).

Em paralelo, avanços recentes em previsão de séries temporais como o *Temporal Fusion Transformer* (TFT) trouxeram interpretabilidade (atenção temporal/variável) e desempenho multi-horizonte, útil quando o preenchimento é etapa prévia para aplicações como previsão de geração solar/vento, demanda energética, ou índices ambientais (Lim et al., 2021). No ecossistema de tempo e clima, redes profundas 3D em larga escala já rivalizam abordagens numéricas tradicionais em certas janelas de previsão (Bi et al., 2023), sinalizando maturidade do DL para problemas atmosféricos.

Justifica estudar este tema propondo uma metodologia do estado da arte combinando duas abordagens robustas: A utilização da reanálise ERA5, previamente validada cientificamente no cenário brasileiro (Araújo et al., 2022), servindo como uma verdade de referência fisicamente consistente para o treinamento e a implementação de arquiteturas Transformer (Baseadas em SAITS e Pangu-Weather), reconhecidas como SOTA na identificação de dependências de longo prazo (Bi et al., 2023; Du; Côté; Liu, 2023). A combinação dessas técnicas possibilitará a construção de um pipeline de imputação de alta precisão para as séries do INMET, resultando em um conjunto de dados robusto e abrangente, fundamental para análises climáticas futuras e para a criação de modelos preditivos.

Diante do contexto, este projeto visa responder à questão de pesquisa: **Como modelos de Inteligência Artificial baseados em Transformers, treinados com dados de reanálise ERA5, podem ser aplicados para a imputação de dados climáticos ausentes (temperatura, precipitação, vento, etc.) em séries temporais de estações meteorológicas do INMET?**

2 Objetivos

2.1 Objetivo geral

Desenvolver e avaliar um modelo computacional baseado na arquitetura Transformer para imputação de dados climáticos multivariados ausentes em séries temporais de estações do INMET, utilizando a base de reanálise ERA5 como dados de treinamento.

2.2 Objetivos específicos

- Realizar uma revisão bibliográfica sobre métodos de imputação de dados climáticos, com foco em Deep Learning (CNN-LSTM) e Transformadores.
- Coletar e pré-processar as séries temporais multivariadas das estações do INMET e dados de reanálise do ERA5 para um período de (2000, até 2024).
- Implementar e comparar baselines KNN, Regressão Linear múltipla, Random Forest.
- Implementar e testar modelos baseados em Transformers como (SAITS, TA-Saits, MSTSIT, CNN-Transformers).

- Avaliar imputação por variável com métricas (MAE, RMSE, R^2).
- Treinar o modelo em um regime auto-supervisionado utilizando os dados completos do ERA5, através de uma abordagem de imputação mascarada (criando buracos artificiais) para que o modelo aprenda a física e a dinâmica atmosférica.

3 REFERENCIAL TEÓRICO

Este capítulo apresenta os conceitos fundamentais dos estudos científicos e o estado da arte da literatura que embasam a metodologia proposta por este trabalho.

3.1 Séries Temporais Climáticas e Dados Ausentes

As Séries temporais são conjuntos de observações indexadas pelo tempo. Em domínios do mundo real, como monitoramento climático (Alejo-Sanchez et al., 2025) ou dados provenientes de sensores ambientais (Nejad et al., 2024), é raro que as séries estejam completas, sem lacunas ou inconsistências. Essas falhas comprometem a continuidade e qualidade dos dados e precisam ser tratadas antes de qualquer análise subsequente Weerakody et al. (2021).

A literatura de previsão em séries temporais avançou significativamente em direção a modelos mais expressivos e interpretáveis. Um dos principais exemplos é o *Temporal Fusion Transformer* (TFT), que combina redes recorrentes, mecanismos de atenção e seleção de variáveis para previsões multihorizonte em cenários complexos do mundo real (Lim et al., 2021). Outro avanço importante envolve modelos de previsão meteorológica baseados em redes neurais tridimensionais de escala global, como o Pangu-Weather, que competem com modelos numéricos tradicionais em janelas específicas de previsão (Bi et al., 2023). Esses avanços reforçam a importância de dados confiáveis e sem lacunas para treinar e avaliar modelos modernos de previsão climática.

Segundo revisões recentes (Alabadla et al., 2022; Lien; Do; Nguyen, 2023), classifica os padrões de ausência em três categorias principais e que impactam a escolha do método de imputação:

- *Missing Completely At Random* (MCAR): É o cenário mais simples, ausência completamente aleatória, sem relação com qualquer variável observada ou não observada;
- *Missing At Random* (MAR): A ausência depende de variáveis observadas;
- *Missing Not At Random* (MNAR): A ausência depende do próprio valor ausente, sendo o caso mais complexo e enviesado.

Tratar erroneamente esses padrões — como aplicar substituição ingênua pela média — pode introduzir vieses significativos e levar a conclusões equivocadas (Alabadla et al., 2022).

3.2 Fontes de Dados para Modelagem Climática

Este trabalho utiliza duas fontes principais: dados observacionais (alvo da imputação) e dados de reanálise (base para o treinamento dos modelos).

3.2.1 Reanálise Atmosférica ERA5 e ERA5-Land

O ERA5 é a quinta geração de reanálise atmosférica global produzida pelo Centro Europeu de Previsão de Tempo de Médio Prazo (ECMWF) no âmbito do programa Copernicus. As reanálises combinam observações históricas (satélites, estações meteorológicas, balões, etc.) com modelos numéricos para formar um conjunto de dados consistente no tempo e no espaço.

O ERA5 cobre o período de 1940 até o presente, com resolução temporal de 1 hora e resolução espacial de aproximadamente 31 km. Já o ERA5-Land é uma versão derivada com foco em variáveis de superfície terrestre, apresentando resolução espacial mais alta (aprox. 9 km), ideal para estudos climáticos de escala local.

As reanálises têm sido amplamente utilizadas para preenchimento de lacunas em dados meteorológicos, como temperatura, precipitação, vento, umidade e radiação. Estudos mostram boa capacidade do ERA5 podendo ser utilizado como um substituto direto ou referência para correção de viés, desde que se considerem adequadamente os efeitos regionais e sazonais. (Araújo et al., 2022), por exemplo, avaliaram a temperatura estimada pelo ERA5-Land em Pernambuco e encontraram bons ajustes médios (com elevado R^2), mas quando utilizado com viés quente em determinados meses (maio-junho) foi pior o desempenho em regiões costeiras, tendo a necessidade de correções antes de do uso aplicado.

Da mesma forma, (Varotsos; Katavoutas; Giannakopoulos, 2023) utilizaram para reconstruir dados de temperatura na Europa, concluindo que o ERA5-Land superou o (outperform) outra fonte de reanálise preservando as tendências temporais dos dados.

3.2.2 Dados Observacionais de Superfície (INMET)

O Instituto Nacional de Meteorologia (INMET) é o serviço meteorológico nacional do Brasil, vinculado ao Ministério da Agricultura e Pecuária, responsável pelo monitoramento operacional do tempo e do clima, bem como pela produção de séries climatológicas de longo prazo (Diniz; Ramos; Rebello, 2018). Desde a década de 1960, o instituto mantém um banco de dados que integra estações meteorológicas convencionais e automáticas distribuídas por todo o país, constituindo uma das principais fontes de dados meteorológicos para pesquisa e aplicações operacionais.

Segundo informações institucionais do próprio INMET (Meteorologia, 2024), suas atribuições incluem o monitoramento contínuo das condições atmosféricas, a emissão de avisos meteorológicos, a previsão de tempo e clima e o apoio científico a

pesquisas e ao desenvolvimento tecnológico. O sistema nacional de coleta e distribuição de dados fornece medições *in situ* de temperatura, precipitação, vento, radiação e umidade, operando 24 horas por dia. O INMET também mantém a maior rede de estações meteorológicas automáticas da América do Sul (Meteorologia, 2024).

Esses dados observacionais constituem o alvo das imputações realizadas neste trabalho. As séries históricas disponíveis variam aproximadamente de 2000 até o presente, embora apresentem lacunas devido a falhas operacionais, interrupções de comunicação ou manutenção.

3.3 Estado da Arte em Imputação de Séries Temporais

A imputação de dados climáticos evoluiu significativamente, saindo de métodos estatísticos simples para arquiteturas complexas de aprendizado profundo de máquina (Alejo-Sanchez et al., 2025).

3.3.1 Métodos Estatísticos e de Machine Learning

Antes dos modelos de Redes Neurais Recorrentes os métodos tradicionais como os de estatísticas e aprendizado de máquina simples, dominavam as imputações de séries temporais climáticas e ambientais que são computacionalmente rápidas e fáceis de serem interpretadas, mas são limitadas quanto a correlações multivariadas e padrões não-lineares. Revisões sobre técnicas recentes de imputações em séries temporais (Zainuddin et al., 2022; Lien; Do; Nguyen, 2023) apontam algumas categorias:

- Métodos de Substituição simples: média global, média sazonal, LOCF;
- Interpolação: linear, cúbica, kriging espaço-temporal;
- Imputação multivariada: *K-Nearest Neighbors* KNN, regressão multivariada, *Random Forest*.

Essas técnicas são relevantes de facéis implementações e interpretações e muitas vezes e muitas vezes fornecem resultados satisfatórios em cenários de lacunas curtas, mas apresentam limitações para estruturas espaço-temporais complexas ou lacunas longas (Alejo-Sanchez et al., 2025). Por isso, são usadas como *baselines* em estudos recentes.

3.3.2 Redes Neurais Recorrentes (RNNs)

As RNNs, especialmente as variantes como *Long Short-Term Memory* (LSTM) e *Gated Recurrent Units* GRU, representam um dos primeiros grandes avanços do Deep Learning para séries temporais. Como revisado por (Weerakody et al., 2021) o modelo GRU-D, por exemplo, foi projetado para lidar diretamente com dados irregulares e faltantes .

Apesar disso, RNNs processam sequências passo a passo, o que prejudica sua capacidade de capturar dependências de longo prazo devido ao desaparecimento do gradiente, mais recentemente modelos baseados em atenção, *Transformers*, vêm corrigindo essas limitações e superando RNNs em diversos cenários, especialmente quando os dados apresentam dependências de longo alcance, lacunas extensas e correlações entre variáveis, modelos baseados em atenção (Vaswani et al., 2017; Albadla et al., 2022; Liu et al., 2023).

3.3.3 Modelos Transformers




Figure 1: The Transformer - model architecture.

Figura 1: *The Transformer* model architecture.

Fonte: Vaswani et al. (2017).

A arquitetura dos *Transformers*, introduzida originalmente para processamento de linguagem natural (Vaswani et al., 2017), resolveu o limitações das RNNs através do mecanismo de Auto-Atenção (*Self-Attention*). Em vez de processar sequencialmente, a auto-atenção permite o modelo olhar para todos os pontos da sequência (passado e

futuro) simultaneamente, calculando a importância para cada ponto e atribuindo pesos. Essa abordagem tem se mostrado eficaz em séries temporais, especialmente em cenários com dependências de longo alcance e dados incompletos, como demonstrado em aplicações recentes (Du; Côté; Liu, 2023; Liu et al., 2023; Hu; Dong; Liu, 2025).

Conforme ilustrado na Figura 1, o *Transformer* é composto, de forma geral, por dois blocos principais:

Encoder: O encoder recebe a sequência de entrada, aplica uma etapa de *embedding* e a soma com o *positional encoding*, que introduz informação de ordem na sequência. Em seguida, cada camada do encoder combina um bloco de *Multi-Head Self-Attention* com uma rede *Position-wise Feed-Forward*, ambos envolvidos por conexões residuais e camadas de normalização.

Decoder: O decoder possui estrutura semelhante, mas inclui um bloco adicional de *Masked Self-Attention* (para que o modelo não veja posições futuras na tarefa original de tradução) e um bloco de atenção cruzada (*encoderdecoder attention*), que permite ao decoder consultar diretamente as representações produzidas pelo encoder.

Em alto nível, o papel da atenção multi-cabeças é permitir que o modelo foque, simultaneamente, em diferentes relações temporais ou posicionais da sequência, enquanto as camadas *feed-forward* refinam essas representações de forma não linear (Vaswani et al., 2017).

Entre os modelos da família dos *Transformers* focados em imputação, dois modelos se destacam são: *SAITS* e o *TA-SAITS*. O *SAITS* é um modelo de imputação baseado em *Self-Attention* desenvolvido para séries multivariadas, onde a rede aprende a reconstruir entradas parcial ou completamente mascaradas a partir de um treinamento auto-supervisionado (Du; Côté; Liu, 2023). O *TA-SAITS*, amplia esse modelo incorporando informações sobre intervalos irregulares entre amostras e estrutura de ausência, essa característica torna a abordagem especialmente eficaz para cenários onde as séries possui falhas não uniformes, comum em dados de estações meteorológicas (Sharma et al., 2023).

Um modelo *Transformer* com arquitetura mais leve proposto por (Yldz; Koç; Koç, 2022), em que utiliza apenas o *Encoder* do *Transformer* em um *autoencoder* para imputação mostrando resultados eficazes com menor custo computacional.

Para dados climáticos, que são intrinsecamente espaço-temporais, as arquiteturas híbridas tem se destacado. Modelos como *CNN-Transformer*, como o CT-MVP proposto por (Hu; Dong; Liu, 2025), que tem uma combinação perfeita, utilizando as CNNs para extrair padrões locais e espaciais, e transformers para capturar as dependências globais e temporais de longo prazo.

4 Procedimentos Metodológicos

Esta pesquisa é classificada, quanto à natureza, como um trabalho de resumo de assunto. De acordo com (Wazlawick, 2009), esse tipo de estudo busca sistematizar o estado da arte de uma área específica do conhecimento. Neste trabalho, o foco é a imputação de dados climáticos com modelos de aprendizado de máquina, em especial arquiteturas baseadas em *Transformers*, e a proposição de um plano experimental para aplicação desses modelos às séries do INMET.

Segundo os objetivos, trata-se de uma pesquisa de caráter exploratório. "As pesquisas exploratórias têm como propósito proporcionar maior familiaridade com o problema, com vistas a torná-lo mais explícito ou a construir hipóteses" (Gil, 2022, p. 27).

Quanto aos procedimentos técnicos, esta pesquisa é bibliográfica e experimental, conforme definido por Wazlawick (2009). A pesquisa bibliográfica envolve a análise de artigos, livros, teses e periódicos científicos (como o Portal de Periódicos da CAPES). De acordo com Gil (2022), a pesquisa bibliográfica segue um processo lógico e ordenado de etapas. Adaptando essas etapas ao contexto deste trabalho, tem-se:

- a) Escolha do tema: imputação de dados climáticos em séries do INMET (2000–2024) com uso combinado de reanálises ERA5/ERA5-Land e modelos baseados em *Transformers*;
- b) Levantamento bibliográfico preliminar: realização de busca inicial em bases de dados de acordo com a área de interesse, visando à familiarização com o tema e à facilitação da definição do problema de pesquisa;
- c) Formulação do problema: *Como modelos de IA baseados em Transformers, combinados com dados de reanálise ERA5/ERA5-Land, podem ser utilizados para imputação de dados climáticos ausentes nas séries do INMET e apoiar projeções e previsões em regiões sem estação?*
- d) Busca de fontes: realização de buscas sistemáticas em bases como Scopus, Web of Science, IEEE Xplore, ScienceDirect, Springer, SciELO e Google Scholar;
- e) Leitura do material: identificação, em cada artigo, do tipo de dado utilizado, dos métodos mais promissores, das formas de lidar com dados irregulares ou faltantes, das métricas e protocolos de avaliação e das principais limitações e recomendações;
- f) Fichamento e organização: elaboração de fichamentos contendo problema, dados, métodos, resultados e contribuições de cada trabalho;
- g) Redação do texto: escrita do TCC, articulando o referencial teórico, os procedimentos metodológicos e os resultados obtidos.

Segundo Wazlawick (2009, p. 23), "a pesquisa experimental caracteriza-se pela manipulação de um aspecto da realidade pelo pesquisador". Neste trabalho, tal mani-

pulação ocorre na geração controlada de cenários de dados ausentes e na comparação entre diferentes modelos de imputação.

4.1 Coleta e Pré-processamento de Dados

4.1.1 Fonte Alvo (INMET)




Figura 2: Rede de estações meteorológicas automáticas do INMET no Brasil.

Fonte: adaptado de INMET.

Serão utilizadas séries temporais das estações automáticas do INMET no período aproximado de 2000 a 2024, abrangendo variáveis como temperatura do ar, precipitação, umidade relativa, pressão atmosférica, velocidade e direção do vento e radiação global.

Inicialmente, serão selecionadas estações com maior quantidade de registros e melhor qualidade de dados para os primeiros experimentos, ampliando-se gradualmente a cobertura das estações consideradas.

O pré-processamento dos dados observacionais envolverá:

- consolidação e padronização de unidades e frequências de amostragem;
- análise de falhas, com mapeamento de todos os dados ausentes (NaN ou valores inválidos) em cada série temporal;
- geração de um "mapa de falhas" representando o alvo de imputação.

4.1.2 Fontes de Treinamento (ERA5/ERA5-Land)

Serão utilizados dados de reanálise ERA5 e ERA5-Land, fornecidos pelo Copernicus Climate Change Service (C3S), que compõem um *dataset* global, fisicamente

Tabela 1: Variáveis das reanálises ERA5 e ERA5-Land utilizadas no estudo.

Variável física	Código	Unidade	Nível / uso no trabalho
Temperatura do ar a 2 m	t2m	K (°C após conversão)	2 m acima da superfície; comparada e combinada com a temperatura observada pelo INMET.
Ponto de orvalho a 2 m	d2m	K (°C após conversão)	Utilizado para o cálculo da umidade relativa do ar.
Pressão de superfície	sp	Pa (hPa)	Pressão ao nível da superfície; comparada com a pressão medida nas estações.
Vento (componente zonal a 10 m)	u10	m s ⁻¹	Componente lesteoeste do vento a 10 m; usada no cálculo da velocidade e direção do vento.
Vento (componente meridional a 10 m)	v10	m s ⁻¹	Componente nortesul do vento a 10 m; usada no cálculo da velocidade e direção do vento.
Rajada de vento a 10 m	fg10	m s ⁻¹	Rajada máxima a 10 m; comparada com a variável de rajada (<i>wind_gust</i>) do INMET.
Radiação de onda curta incidente	ssrd	J m ⁻²	Radiação solar global incidente; convertida para taxa horária e comparada com a radiação global observada.
Precipitação total	tp	m	Lâmina de chuva acumulada; convertida para mm por intervalo e comparada com a precipitação do INMET.

consistente e sem lacunas. A alta correlação dessas reanálises com dados de estações de superfície no Brasil já foi avaliada em estudos anteriores (Araújo et al., 2022; Varotsos; Katavoutas; Giannakopoulos, 2023), tornando-as um *ground truth* adequado para pré-treinamento e calibração dos modelos de imputação.

O ERA5 fornece campos globais com resolução aproximada de 0,25°, enquanto o ERA5-Land possui resolução mais fina, em torno de 0,10°, concentrada em variáveis de superfície.

O pré-processamento dos dados de reanálise incluirá:

- extração dos dados para a janela geográfica do Brasil;
- cálculo de variáveis derivadas, como umidade relativa (a partir de temperatura e ponto de orvalho) e velocidade/direção do vento (a partir dos componentes *u10* e *v10*), quando necessário;
- normalização das variáveis com base em média e desvio padrão do conjunto de treino;
- *mapeamento estação-grade*, associando cada estação do INMET ao ponto de grade mais próximo no *grid* do ERA5/ERA5-Land;
- geração de máscaras de dados ausentes artificiais (aleatórias e em blocos), seguindo estratégias similares às empregadas por SAITS, TA-SAITS, MTSI-T e

modelos CNN–Transformer para avaliar o desempenho em diferentes padrões de falhas (Du; Côté; Liu, 2023; Hu; Dong; Liu, 2025; Sharma et al., 2023; Yldz; Koç; Koç, 2022; Alejo-Sanchez et al., 2025).

Todas as etapas serão implementadas em *scripts* ou *notebooks* em Python, utilizando bibliotecas como *pandas*, *xarray*, *netCDF4* e *numpy*, armazenando os resultados intermediários em formatos eficientes, como Parquet (dados tabulares) e NetCDF/Zarr (dados espaço-temporais).

4.2 Geração de Cenários de Dados Ausentes

Para avaliar de forma controlada os métodos de imputação, serão geradas máscaras artificiais de dados ausentes sobre as séries observadas, considerando os seguintes cenários:

- Remoção aleatória: remoção de frações fixas de observações, de 10% a 80%, selecionadas aleatoriamente em cada variável;
- Ausência em blocos contíguos: remoção de janelas contínuas de 6h, 24h e 72h em posições aleatórias, simulando falhas prolongadas de sensores ou de comunicação;
- Ausência de variável específica: remoção total de determinadas variáveis em intervalos de tempo, reproduzindo falhas recorrentes de um sensor específico;
- Amostragem irregular: remoção de *timestamps* inteiros, criando buracos no eixo temporal, para avaliar métodos que incorporam informação de intervalo entre amostras (como TA-SAITS e GRU-D).

4.3 Modelos de Imputação

Para avaliar a eficácia da abordagem proposta, serão implementados tanto modelos de *benchmark* quanto modelos de estado da arte (*State of the Art* – SOTA).

4.3.1 Baselines Estatísticos e de Machine Learning

Entre os modelos de referência, destacam-se:

- Regressão linear múltipla: Neste método, o valor de uma variável ausente (variável dependente, Y) é estimado como uma combinação linear das outras variáveis climáticas presentes (variáveis independentes, $X_1, X_2, \dots, X_n$) no mesmo instante de tempo.;
- *K-Nearest Neighbors (KNN) Imputer*: preenche cada falha utilizando a média (ou mediana) dos k vizinhos mais próximos;
- *Random Forest (MissForest)*: método baseado em árvores de decisão que treina uma floresta para prever valores ausentes a partir das variáveis observadas.

4.3.2 Modelos de Deep Learning

Serão considerados modelos de aprendizado profundo, incluindo:

- SAITS: modelo de imputação baseado em *self-attention*, treinado de forma auto-supervisionada com máscaras aleatórias nas entradas, conforme Du, Côté e Liu (2023);
- TA-SAITS: extensão *time-aware* que incorpora intervalos entre amostras e padrões de ausência (Sharma et al., 2023);
- CNN–Transformer espaço-temporal: modelo híbrido baseado em Hu, Dong e Liu (2025), combinando convoluções para capturar padrões locais e atenção para dependências de longo alcance em dados atmosféricos multivariados;

Outros modelos baseados em *Transformers*, como arquiteturas mais leves que utilizam apenas o *encoder* em estruturas de *autoencoder*, serão considerados conforme Yldz, Koç e Koç (2022) e revisões recentes (Alejo-Sanchez et al., 2025).

4.4 Estratégia de Validação e Métricas de Desempenho

A validação dos modelos seguirá uma abordagem de *masking* controlado. Dados conhecidos das séries temporais serão removidos artificialmente (simulando lacunas) e, em seguida, os valores imputados serão comparados com os valores reais. Essa abordagem segue o padrão observado em estudos recentes de imputação em clima e séries de sensores (Alejo-Sanchez et al., 2025; Hu; Dong; Liu, 2025; Lien; Do; Nguyen, 2023).

Serão utilizadas, entre outras, as seguintes métricas quantitativas:

- Erro Absoluto Médio (MAE) é definido pela Equação 1:

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \quad (1)$$

- Raiz do Erro Quadrático Médio (RMSE) é apresentado na Equação 2:

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2} \quad (2)$$

- Coeficiente de determinação (R^2) é descrito na Equação 3:

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2} \quad (3)$$

Onde:

- y_i = valor verdadeiro;
- $\hat{y}_i$ = valor imputado pelo modelo;
- $\bar{y}$ = média dos valores verdadeiros;
- N = número total de amostras.

Nos cenários sintéticos, as lacunas geradas artificialmente, permitindo comparação direta com o valor original, já em cenários reais, será considerada a comparação com estações de melhor qualidade dos dados.

Serão analisados três cenários distintos:

- Lacunas curtas (short-gap): remoção de até 20% dos dados em blocos curtos;
- Lacunas médias (medium-gap): remoção de até 50% dos dados observados em blocos de comprimento intermediário;
- Lacunas longas (long-gap): remoção de até 80% dos dados em blocos longos.

Os resultados dos modelos de *benchmark* e dos modelos propostos serão comparados sistematicamente com os dados reais que foram ocultados, permitindo avaliar ganhos de desempenho e robustez.

4.5 Ambiente Computacional

Os experimentos serão executados em dois ambientes de *hardware* distintos.

1) *Desktop*

- Processador: AMD Ryzen Threadripper Pro 5965WX;
- Memória RAM: 384 GB DDR4 (6 × 64 GB);
- Placa de vídeo: 3 × NVIDIA RTX A4000 16 GB GDDR6;
- Sistema operacional: Linux.

Função principal: execução de experimentos, simulações e visualização de resultados com alto desempenho.

2) *Desktop*

- Processador: Intel Core i5-12400F;
- Placa-mãe: MSI H610M-G DDR4;
- Memória RAM: 32 GB DDR4 (2 × 16 GB);
- GPU: NVIDIA RTX 4060 Ti Ventus 3X 8 GB GDDR6;
- Sistema operacional: Windows 11 Pro.

Função principal: execução de experimentos, simulações e visualização de resultados em ambiente de desenvolvimento complementar.

5 Resultados esperados

Espera-se que os resultados deste trabalho possam contribuir:

- Obtendo um modelo de IA (baseado em Transformer) treinado e validado, capaz de realizar a imputação de dados climáticos multivariados;
- Resultados quantitativos que demonstrem a superioridade do modelo Transformer em relação aos métodos de benchmark, especialmente em cenários de lacunas de dados longas;
- O principal produto deste trabalho é ter um *dataset* completo, coeso e validado das séries temporais das estações do INMET, com as falhas preenchidas por

inferência do modelo;

- Com este *dataset* servirá como um alicerce fundamental para focos na previsão (interpolação espacial) de variáveis climáticas para regiões do Brasil que não possuem cobertura de estações meteorológicas.

6 Atividades/Cronograma

6.1 Lista de Atividades

- Revisão bibliográfica
 - Pesquisa de literatura relevante ao tema;
 - Compilação e análise de bases teóricas.
- Análise de trabalhos correlatos
 - Identificação de trabalhos similares;
 - Comparação de metodologias e resultados.
- Escrita do TCC1
- Defesa do TCC1
 - Preparação da apresentação;
 - Apresentação e defesa do TCC1.
- Desenvolvimento do estudo de caso (TCC2)
 - Seleção e delimitação do caso;
 - Coleta das bases de dados e informações.
- Análise do estudo de caso (TCC2)
 - Interpretação e análise dos dados coletados;
 - Formulação das conclusões preliminares.
- Estudos e Revisão em Python
 - Reforço dos fundamentos da linguagem;
 - Aprendizagem de redes neurais e modelos modernos;
 - Implementação dos benchmarks;
 - Comparação com modelos *baselines*.
- Escrita do TCC2
- Defesa do TCC2
 - Preparação da apresentação final;
 - Apresentação e defesa perante a banca.
- Correção e entrega final do TCC2
 - Ajustes solicitados pela banca;
 - Entrega da versão final.

6.2 Cronograma

Ano	2025											
Mês	Ago	Set	Out	Nov	Dez	Jan	Fev	Mar	Abr	Mai	Jun	Jul
Revisão bibliográfica												
Análise de trabalhos correlatos												
Escrever TCC1												
Defender TCC1												
Revisão da linguagem Python												
Estudo de caso												
Análise do estudo de caso												
Escrever TCC2												
Defender TCC2												
Corrigir e entregar TCC2												

Referências

ALABADLA, Mustafa; SIDI, Fatimah; ISHAK, Iskandar; IBRAHIM, Hamidah; AFFENDEY, Lilly Suriani; CHE ANI, Zafienas; JABAR, Marzanah A.; BUKAR, Umar Ali; DEVARAJ, Navin Kumar; MUDA, Ahmad Sobri; THAREK, Anas; OMAR, Noritah; JAYA, M. Izham Mohd. Systematic Review of Using Machine Learning in Imputing Missing Values. **IEEE Access**, v. 10, p. 44483–44502, 2022. Disponível em: <<https://ieeexplore.ieee.org/document/9762231>>. Acesso em: 9 nov. 2025.

ALEJO-SANCHEZ, Lizette Elena; MÁRQUEZ-GRAJALES, Aldo; SALAS-MARTÍNEZ, Fernando; FRANCO-ARCEGA, Anilu; LÓPEZ-MORALES, Virgilio; ACEVEDO-SANDOVAL, Otilio Arturo; GONZÁLEZ-RAMÍREZ, César Abelardo; VILLEGAS-VEGA, Ramiro. Missing data imputation of climate time series: A review. **MethodsX**, v. 15, p. 103455, dez. 2025. Disponível em: <<https://linkinghub.elsevier.com/retrieve/pii/S2215016125003000>>. Acesso em: 2 nov. 2025.

ARAÚJO, Caio Sérgio Pereira De; SILVA, Ivis Andrei Campos E; IPPOLITO, Matteo; ALMEIDA, Ceres Duarte Guedes Cabral De. Evaluation of air temperature estimated by ERA5-Land reanalysis using surface data in Pernambuco, Brazil. **Environmental Monitoring and Assessment**, v. 194, n. 5, p. 381, maio 2022. Disponível em: <<https://link.springer.com/10.1007/s10661-022-10047-2>>. Acesso em: 2 nov. 2025.

BI, Kaifeng; XIE, Lingxi; ZHANG, Hengheng; CHEN, Xin; GU, Xiaotao; TIAN, Qi. Accurate medium-range global weather forecasting with 3D neural networks. **Nature**, v. 619, n. 7970, p. 533–538, jul. 2023. Publisher: Nature Publishing Group. Disponível em: <<https://www.nature.com/articles/s41586-023-06185-3>>. Acesso em: 9 nov. 2025.

DINIZ, Francisco de Assis; RAMOS, Andrea Malheiros; REBELLO, Expedito Ronald Gomes. Brazilian climate normals for 1981-2010. **Pesquisa Agropecuária Brasileira**, v. 53, p. 131–143, 2018. Publisher: Embrapa Secretaria de Pesquisa e Desenvolvimento; Pesquisa Agropecuária Brasileira. Disponível em: <<https://www.scielo.br/j/pab/a/WrrC5Btrkx4sRjgr8dKFBdB/?lang=en>>. Acesso em: 29 nov. 2025.

DU, Wenjie; CÔTÉ, David; LIU, Yan. SAITS: Self-attention-based imputation for time series. **Expert Systems with Applications**, v. 219, 2023. Publisher: Elsevier Ltd.

GIL, Antônio Carlos. **Como elaborar projetos de pesquisa**. 7. ed. Rio de Janeiro: Atlas, 2022.

HU, Jiahui; DONG, Wenjun; LIU, Alan Z. **Imputing Missing Long-Term Spatiotemporal Multivariate Atmospheric Data with CNN-Transformer Machine Learning**. [S.l.]: arXiv, 1 set. 2025. arXiv: 2509.01141[physics]. Disponível em: <<http://arxiv.org/abs/2509.01141>>. Acesso em: 2 nov. 2025.

LIEN, P. Le; DO, Tu T.; NGUYEN, Thu. **Data Imputation for Multivariate Time-series Data**. *In*: 2023 15TH INTERNATIONAL CONFERENCE ON KNOWLEDGE AND SYSTEMS ENGINEERING (KSE). **2023 15th International Conference on Knowledge and Systems Engineering (KSE)**. *[[S.l.]: [s.n.]]*, out. 2023. p. 1–6. Disponível em: <<https://ieeexplore.ieee.org/document/10299484>>. Acesso em: 9 nov. 2025.

LIM, Bryan; ARIK, Sercan Ö.; LOEFF, Nicolas; PFISTER, Tomas. Temporal Fusion Transformers for interpretable multi-horizon time series forecasting. **International Journal of Forecasting**, v. 37, n. 4, p. 1748–1764, 1 out. 2021. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0169207021000637>>. Acesso em: 9 nov. 2025.

LIU, Mingxuan; LI, Siqu; YUAN, Han; ONG, Marcus Eng Hock; NING, Yilin; XIE, Feng; SAFFARI, Seyed Ehsan; SHANG, Yuqing; VOLOVICI, Victor; CHAKRABORTY, Bibhas; LIU, Nan. Handling missing values in healthcare data: A systematic review of deep learning-based imputation techniques. **Artificial Intelligence in Medicine**, v. 142, p. 102587, 1 ago. 2023. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S093336572300101X>>. Acesso em: 9 nov. 2025.

METEOROLOGIA, Instituto Nacional de. **Sobre o INMET**. Ministério da Agricultura e Pecuária. 2024. Disponível em: <<https://portal.inmet.gov.br/sobre>>. Acesso em: 28 nov. 2025.

NEJAD, Amin Shoari; ALAIZ-RODRÍGUEZ, Rocío; MCCARTHY, Gerard D.; KELLEHER, Brian; GREY, Anthony; PARNELL, Andrew. SERT: A transformer based model for multivariate temporal sensor data with missing values for environmental monitoring. **Computers & Geosciences**, v. 188, p. 105601, 1 jun. 2024. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0098300424000840>>. Acesso em: 2 nov. 2025.

SHARMA, Ankit; SAMON, Thiruvengadam; VELLANDURAI, Akhash; KUMAR, Vinoth. **TA-Saits: Time Aware-Self Attention based Imputation of Time Series algorithm for Partially Observable Multi -Variate Time Series**. *In*: 2023 INTERNATIONAL CONFERENCE ON MACHINE LEARNING AND APPLICATIONS (ICMLA). **2023 International Conference on Machine Learning and Applications (ICMLA)**. *[[S.l.]: [s.n.]]*, dez. 2023. p. 2228–2233. Disponível em: <<https://ieeexplore.ieee.org/document/10459819>>. Acesso em: 9 nov. 2025.

VAROTSOS, Konstantinos V.; KATAVOUTAS, George; GIANNAKOPOULOS, Christos. On the Use of Reanalysis Data to Reconstruct Missing Observed Daily Temperatures in Europe over a Lengthy Period of Time. **Sustainability**, v. 15, n. 9, p. 7081, 23 abr. 2023. Disponível em: <<https://www.mdpi.com/2071-1050/15/9/7081>>. Acesso em: 28 set. 2025.

VASWANI, Ashish; SHAZEER, Noam; PARMAR, Niki; USZKOREIT, Jakob; JONES, Llion; GOMEZ, Aidan N.; KAISER, Lukasz; POLOSUKHIN, Illia. **Attention Is All You Need**. arXiv.org. 12 jun. 2017. Disponível em: <<https://arxiv.org/abs/1706.03762v7>>. Acesso em: 15 nov. 2025.

WAZLAWICK, Raul Sidnei. **Metodologia de pesquisa para ciência da computação**. Rio de Janeiro: Elsevier, 2009. v. 2.

WEERAKODY, Philip B.; WONG, Kok Wai; WANG, Guanjin; ELA, Wendell. A review of irregular time series data handling with gated recurrent neural networks. **Neurocomputing**, v. 441, p. 161–178, 21 jun. 2021. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0925231221003003>>. Acesso em: 9 nov. 2025.

YILDIZ, A. Yarkn; KOÇ, Emirhan; KOÇ, Aykut. Multivariate Time Series Imputation With Transformers. **IEEE Signal Processing Letters**, v. 29, p. 2517–2521, 2022. Disponível em: <<https://ieeexplore.ieee.org/document/9964035>>. Acesso em: 9 nov. 2025.

ZAINUDDIN, Aznilinda; HAIRUDDIN, Muhammad Asraf; YASSIN, Ahmad Ihsan Mohd; LATIFF, Zatul Iffah Abd; AZHAR, Aziemah. **Time Series Data and Recent Imputation Techniques for Missing Data: A Review**. In: 2022 International Conference on Green Energy, Computing and Sustainable Technology (GECOST). *[S.l.]*: *[s.n.]*, out. 2022. p. 346–350. Disponível em: <<https://ieeexplore.ieee.org/document/10010499>>. Acesso em: 9 nov. 2025.